รหัส CS2569/SCS3-24 • บทพูดฉบับเต็ม 15 นาที (21 สไลด์)

บทพูดนำเสนอ (ตามสไลด์ Canva 21 หน้า — ฉบับเต็ม 15 นาที)

รหัสโครงงาน: CS2569/SCS3-24

เวลารวมประมาณ: 15 นาที แบ่งคนละครึ่ง

- **ช่วงที่ 1 (0:00 – 7:00 | สไลด์ 1–10):** นายสัพพัญญู คำตุ้ม — ที่มา ช่องว่าง วัตถุประสงค์ ทฤษฎี ข้อมูล การออกแบบการทดลอง และตัวชี้วัด
- **ช่วงที่ 2 (7:00 – 15:00 | สไลด์ 11–21):** นายปิยะพล ตุ่นป่า — ผลการทดลองที่ 1–2, PSNR vs AUC, แผน XAI, ข้อจำกัด และสรุป

> ถ้าต้องตัดให้เหลือ 10 นาที: ข้ามสไลด์ 5 (ทฤษฎี Noise) พูดสไลด์ 8–9 รวมกัน และพูดสไลด์ 11–12 รวมกันเหลือ 1 นาที

ช่วงที่ 1 (นายสัพพัญญู คำตุ้ม)

สไลด์ 1: หน้าปก (20 วินาที | 0:00 – 0:20)

> "สวัสดีครับอาจารย์ ดร.พบพร ด่านวิรุทัย และคณะกรรมการทุกท่าน ผมนายสัพพัญญู คำตุ้ม และนายปิยะพล ตุ่นป่า ขอนำเสนอโครงงานเรื่อง **การเพิ่มประสิทธิภาพการตรวจจับภาวะปอดอักเสบจากภาพเอกซเรย์ทรวงอก ด้วยการลดสัญญาณรบกวนและปัญญาประดิษฐ์ที่อธิบายได้** ครับ"

สไลด์ 2: ที่มาและความสำคัญของปัญหา (50 วินาที | 0:20 – 1:10)

> "Infiltration หรือภาวะฝ้าในปอด เกิดจากของเหลว เซลล์อักเสบ หรือหนองสะสมในถุงลม ด่านแรกที่ใช้ตรวจคือภาพเอกซเรย์ทรวงอก แต่จำนวนภาพเพิ่มขึ้นเร็วกว่าจำนวนรังสีแพทย์
> ปัญหาคือรอยโรคนี้เป็นฝ้าจาง ๆ ไม่มีขอบชัด กลืนไปกับเนื้อปอดและซี่โครง แพทย์แต่ละคนจึงอ่านผลไม่ตรงกัน
> ถ้าใช้ CNN ช่วย ก็แม่นได้ระดับใกล้ผู้เชี่ยวชาญ แต่เป็นกล่องดำ เราไม่รู้ว่าโมเดลดูรอยโรคจริง หรือดูสายระโยงหรือ Noise ในภาพแทนครับ"

สไลด์ 3: ทำไมต้องศึกษา Denoising คู่กับ XAI (50 วินาที | 1:10 – 2:00)

> "จากงานที่ผ่านมา เราเห็นช่องว่าง 2 เรื่องครับ
> **เรื่องแรก** Infiltration ได้ F1-Score ต่ำกว่าโรคที่ขอบชัดอย่าง Cardiomegaly และ Heatmap จาก Grad-CAM หรือ SHAP มักไม่ตรงกับบริเวณที่ฝ้ากระจายอยู่จริง (Chrysoula, 2023)
> **เรื่องที่สอง** Noise ทำให้ผลของ XAI ไม่นิ่ง แต่ถ้าลด Noise แรงไป ภาพจะเรียบเกิน หรือ Over-smoothing จนฝ้าบาง ๆ หายไปด้วย และงานส่วนใหญ่ดู Heatmap ด้วยตาแล้วสรุป ไม่ได้วัดเป็นตัวเลข และไม่ได้เทียบกันภายใต้เงื่อนไขเดียวกันครับ"

สไลด์ 4: วัตถุประสงค์ (40 วินาที | 2:00 – 2:40)

> "งานนี้จึงมีวัตถุประสงค์ 4 ข้อครับ
> ข้อ 1 เปรียบเทียบวิธีลด Noise หลายแบบหลายระดับ ว่าช่วยให้แยก Infiltration ได้ดีขึ้นแค่ไหน บน NIH และ VinBigData
> ข้อ 2 เทรน ResNet-50 ภายใต้เงื่อนไขเดียวกันทุกวิธี แล้วทดสอบกับ Noise 5 แบบ แบบละ 3 ระดับ รวมกับภาพต้นฉบับเป็น 16 สภาวะ
> ข้อ 3 ใช้ Grad-CAM และ SHAP ดูว่าโมเดลตัดสินใจจากบริเวณไหน
> และข้อ 4 วัดเป็นตัวเลขว่าการลด Noise ทำให้ XAI ชี้รอยโรคแม่นขึ้นหรือไม่ ด้วย Pointing Game, Energy Inside Box และ IoU เทียบกับกรอบของรังสีแพทย์ครับ"

สไลด์ 5: Noise 5 ตระกูล และวิธีลด Noise (45 วินาที | 2:40 – 3:25)

> "Noise ที่เราจำลองมี 5 แบบครับ Gaussian มาจากวงจรของตัวรับภาพ Poisson มาจากจำนวนโฟตอนน้อยเมื่อใช้รังสีต่ำ Poisson–Gaussian คือสองแบบรวมกันซึ่งใกล้กับเครื่องจริงที่สุด Salt-and-Pepper คือพิกเซลเสียเป็นจุดขาวดำ และ Speckle เป็น Noise แบบคูณที่ทำให้ลายเนื้อเยื่อเพี้ยน
> ฝั่งวิธีลด Noise เรามี Median Filter ที่เด่นกับจุดขาวดำแต่ถ้า kernel ใหญ่จะเบลอ, CLAHE ร่วมกับ DWT ที่ปรับ contrast และตัดสัมประสิทธิ์ความถี่สูง, DAE ร่วมกับ CLAHE ที่ให้โครงข่ายเรียนรู้การลบ Noise และการรวมหลายย่านความถี่ด้วย DFT ก่อนป้อนเข้า ResNet-50 ครับ"

สไลด์ 6: ชุดข้อมูลและการเตรียมภาพ (45 วินาที | 3:25 – 4:10)

> "เราใช้ 2 ชุดข้อมูลครับ NIH ChestX-ray14 ใช้ภาพที่มี Infiltration อย่างเดียวเทียบกับ No Finding ส่วน VinBigData ใช้ Infiltration รวมภาพที่มีโรคร่วม เทียบกับ No Finding ทั้งสองชุดมีกรอบรอยโรคจากรังสีแพทย์ไว้ใช้ประเมิน XAI ภาพทุกวิธีถูกแปลงเป็นมาตรฐานเดียวกัน คือ 256×256 ตอนลด Noise และ 224×224 ตอนเข้า ResNet-50
> การทดลองที่ 1 ใช้ Train 400, Validation 80, Test 100 ภาพ ส่วนการทดลองที่ 2 เราคัดภาพที่มี Noise เดิมต่ำที่สุดด้วย Wavelet MAD เพื่อใช้เป็นภาพอ้างอิงก่อนเติม Noise ได้ Train 320, Validation 80, Test 100 ภาพ ทุกชุดสมดุล 50:50 ครับ"

สไลด์ 7: การทดลองที่ 1 (45 วินาที | 4:10 – 4:55)

> "การทดลองที่ 1 ดูว่าการเพิ่มความแรงของการลด Noise จาก L1 ไป L4 ส่งผลอย่างไรบนภาพต้นฉบับครับ
> เรามี Baseline 1 สภาวะ และ 5 กลุ่มวิธี กลุ่มละ 4 ระดับ คือ Median, CLAHE → DWT, DAE → CLAHE, Pure DWT และการแยกย่านความถี่ด้วย DWT ซึ่งเก็บเฉพาะย่านต่ำ กลาง สูง หรือ Selective DWT รวม 21 สภาวะ
> ทุกสภาวะเทรน ResNet-50 แยก 1 โมเดล ใช้ threshold การจำแนก 0.5 และใช้โมเดลจาก epoch สุดท้ายเหมือนกันทุกวิธีครับ"

สไลด์ 8: การทดลองที่ 2 — Noise 16 สภาวะ (35 วินาที | 4:55 – 5:30)

> "การทดลองที่ 2 ทดสอบความทนทานต่อ Noise ครับ เราเติม Noise 5 แบบ แบบละ 3 ระดับ N1 ถึง N3 ตามตาราง เช่น Gaussian ใช้ σ 0.02, 0.05, 0.10 และ Poisson ใช้ peak count 500, 100, 30 ซึ่งยิ่งน้อยยิ่งแรง รวมกับภาพ Clean เป็น 16 สภาวะ ทั้งตอน validation และ test ใช้ Noise ชุดเดิมกับทุกวิธี เพื่อให้เทียบกันได้ครับ"

สไลด์ 9: การทดลองที่ 2 — 12 วิธี (45 วินาที | 5:30 – 6:15)

> "วิธีที่เทียบมี 12 วิธีครับ Baseline, Median 3 ระดับ, DWT → CLAHE 3 ระดับ, DAE → CLAHE 3 ระดับ และวิธีที่รวมหลายมุมมองอีก 2 วิธี คือ DWT Fusion 5 views และ DFT Fusion 3 views ที่แยกย่านความถี่ต่ำ กลาง สูง
> ต่างจากการทดลองที่ 1 ตรงที่รอบนี้แต่ละวิธีเลือกโมเดลจาก epoch ที่ validation loss ต่ำที่สุด และหา threshold ของตัวเองด้วย Youden's J บน validation เช่น Median L1 ได้ 0.606 DAE → CLAHE L2 ได้ 0.613 แล้วใช้ค่านั้นค่าเดียวกับ test ทุกสภาวะ Noise ของวิธีนั้น ชุด test ไม่ได้ใช้เลือกอะไรเลยครับ"

สไลด์ 10: ตัวชี้วัด 3 มิติ (45 วินาที | 6:15 – 7:00)

> "เราวัดผล 3 ด้านครับ
> ด้านแรกคุณภาพภาพ ใช้ PSNR และ SSIM เทียบกับภาพก่อนเติม Noise
> ด้านที่สองการจำแนกโรค ใช้ F1, Recall, Specificity และตัวหลักคือ ROC-AUC กับ PR-AUC ซึ่งไม่ขึ้นกับ threshold จึงใช้เทียบข้ามวิธีได้ แม้แต่ละวิธีจะมี threshold ไม่เท่ากัน
> ด้านที่สามความแม่นยำของ XAI คือดูว่าจุดที่ Heatmap สูงสุดตกในกรอบแพทย์ไหม ความร้อนอยู่ในกรอบกี่เปอร์เซ็นต์ และ IoU ระหว่างบริเวณที่ Heatmap ชี้กับกรอบ ต่อจากนี้ปิยะพลจะนำเสนอผลการทดลองครับ"

ช่วงที่ 2 (นายปิยะพล ตุ่นป่า)

สไลด์ 11: ผลการทดลองที่ 1 — NIH (55 วินาที | 7:00 – 7:55)

> "ผลการทดลองที่ 1 บน NIH ครับ เส้นประคือ Baseline ซึ่งได้ ROC-AUC 0.593
> วิธีที่ดีกว่า Baseline ชัดคือ Pure DWT L1 ได้ 0.662 และ DAE → CLAHE L1 ได้ 0.616 แต่พอเพิ่มความแรง ทั้งสองกลุ่ม AUC ลดลง เช่น DAE → CLAHE L3 เหลือ 0.501 แปลว่าลด Noise เบา ๆ ช่วย แต่แรงไปเริ่มเสียข้อมูลรอยโรค
> ส่วน Median AUC ค่อย ๆ ขึ้นจาก 0.530 เป็น 0.588 แต่ยังไม่เกิน Baseline และ CLAHE → DWT L1 ได้ F1 สูงสุด 0.705 แต่ AUC แค่ 0.508 เพราะทายว่าเป็นโรคถึง 89 จาก 100 ภาพ ค่า F1 จึงสูงแต่แยกโรคได้ไม่ดีครับ"

สไลด์ 12: ผลการทดลองที่ 1 — VinBigData (50 วินาที | 7:55 – 8:45)

> "บน VinBigData ภาพต้นฉบับชัดอยู่แล้ว Baseline ได้ Accuracy 0.92 และ AUC 0.968 ซึ่งแทบไม่มีวิธีไหนเกิน มีแค่ Median L3 ที่ AUC 0.968 เท่า Baseline
> จุดที่เห็นชัดคือระดับ L4 Median Accuracy ตกจาก 0.91 ที่ L3 เหลือ 0.87 และ CLAHE → DWT ตกจาก 0.89 เหลือ 0.85 ซึ่งตรงกับภาวะ Over-smoothing คือกรองแรงจนรายละเอียดของฝ้าหายไป
> สรุปการทดลองที่ 1 คือ ภาพที่สะอาดอยู่แล้วไม่ได้ประโยชน์จากการลด Noise มากนัก และความแรงที่เหมาะคือระดับเบาถึงกลางครับ"

สไลด์ 13: ตัวอย่างภาพหลังเติม Noise (30 วินาที | 8:45 – 9:15)

> "ก่อนดูผลการทดลองที่ 2 นี่คือตัวอย่างภาพเดียวกันใน 4 สภาวะครับ กรอบสีส้มคือรอยโรคที่แพทย์ระบุ จะเห็นว่าที่ Salt-and-Pepper N3 กับ Poisson–Gaussian N3 ฝ้าในกรอบแทบมองไม่เห็นด้วยตาแล้ว ซึ่งเป็นสภาวะที่เราอยากรู้ว่าการลด Noise จะช่วยโมเดลได้แค่ไหนครับ"

สไลด์ 14: ผลการทดลองที่ 2 — NIH (55 วินาที | 9:15 – 10:10)

> "นี่คือค่าเฉลี่ยจาก 16 สภาวะบน NIH ครับ เส้นประคือ Baseline AUC 0.637 Accuracy 57.44%
> อันดับ 1 คือ **DAE → CLAHE L2** ได้ AUC 0.671 และ Accuracy 62.13% เพิ่มขึ้น 4.69 จุด
> DFT Fusion ได้ AUC 0.640 สูงกว่า Baseline เล็กน้อย แต่ Accuracy เท่ากัน ส่วน Median L1 ได้ Accuracy เพิ่ม 2.69 จุด แต่ AUC ต่ำกว่า Baseline เล็กน้อย
> วิธีที่ใช้ Wavelet ทั้ง CLAHE + DWT และ DWT Fusion 5 views ได้ AUC ต่ำกว่า Baseline บนชุดนี้ครับ"

สไลด์ 15: ผลการทดลองที่ 2 — VinBigData (45 วินาที | 10:10 – 10:55)

> "บน VinBigData ค่าทั้งหมดสูงมากครับ Baseline AUC 0.9967 Accuracy 95.38%
> อันดับ 1 คือ **DFT Fusion** AUC 0.9991 Accuracy 97.81% ถ้านับเฉพาะวิธีภาพเดียว DAE → CLAHE L2 ยังเป็นอันดับ 1 ที่ 96.50% ตรงกับ NIH
> ส่วน DWT Fusion 5 views ตกลงเหลือ 91.19% ซึ่งไปทางเดียวกับ NIH ว่าการรวม Wavelet หลายระดับยังไม่ช่วย
> ข้อควรระวังคือค่าบนชุดนี้ใกล้ 1 หมดแล้ว ความต่างเล็ก ๆ จึงต้องยืนยันเพิ่มครับ"

สไลด์ 16: แต่ละวิธีเหมาะกับ Noise คนละแบบ (50 วินาที | 10:55 – 11:45)

> "เมื่อแยกดูตามชนิด Noise บน NIH ครับ ไม่มีวิธีไหนชนะทุกแบบ
> Salt-and-Pepper วิธีที่ดีที่สุดคือ Median L1 AUC เพิ่มจาก 0.603 เป็น 0.699 มากที่สุดในตาราง ซึ่งตรงกับหลักการของ Median ที่เด่นกับจุดขาวดำ
> ส่วน Gaussian, Poisson และ Poisson–Gaussian ชนะด้วย DAE → CLAHE L3 และ Speckle ชนะด้วย DAE → CLAHE L2
> ฝั่ง VinBigData ดูที่ Accuracy วิธีที่ดีที่สุดในแต่ละชนิด Noise ดีกว่า Baseline ทุกแบบ ส่วนใหญ่ชนะด้วย DFT Fusion แปลว่าถ้ารู้ชนิด Noise ของเครื่อง ควรเลือกวิธีให้ตรงกับชนิดนั้นครับ"

สไลด์ 17: PSNR สูง ไม่ได้แปลว่าโมเดลแม่น (55 วินาที | 11:45 – 12:40)

> "สไลด์นี้คือหลักฐานของ Over-smoothing ครับ ดูที่ Gaussian N3 บน NIH
> Median L3 ให้ภาพใกล้ต้นฉบับที่สุด PSNR 29.79 dB SSIM 0.78 แต่ AUC กลับตกจาก 0.669 ของ Baseline เหลือ 0.562 เพราะเกลี่ยจนขอบฝ้าหายไป
> ขณะที่ DAE → CLAHE L3 มี PSNR แค่ 20.64 dB เพราะ CLAHE เพิ่ม contrast ทำให้ภาพต่างจากต้นฉบับ แต่ได้ AUC สูงสุด 0.704
> กราฟด้านขวาก็เห็นว่าจุดที่ PSNR สูงไม่ได้อยู่ด้านบน ข้อสรุปคือต้องวัดทั้งคุณภาพภาพและผลการจำแนกแยกกัน จะใช้ PSNR แทนความแม่นยำไม่ได้ครับ"

สไลด์ 18: แผนการประเมิน XAI ระยะถัดไป (40 วินาที | 12:40 – 13:20)

> "สำหรับระยะถัดไป เราเลือก **DAE → CLAHE L2** เป็นวิธีหลัก เพราะเป็นอันดับ 1 ของวิธีภาพเดียวทั้ง 2 ชุดข้อมูล และเก็บ Baseline, Median L1 และ DFT Fusion ไว้เทียบ
> ภาพตัวอย่างนี้คือ Grad-CAM เทียบกับกรอบแพทย์ และ SHAP ที่ดูว่าพิกเซลไหนสนับสนุนการทายว่าเป็นโรค ขั้นต่อไปเราจะวัดด้วย Pointing Game, Energy Inside Box และ IoU ว่าลด Noise แล้ว Heatmap ชี้ตรงขึ้นจริงไหม และฝึกซ้ำหลาย seed เพื่อยืนยันผลครับ"

สไลด์ 19: ขอบเขตและข้อจำกัด (40 วินาที | 13:20 – 14:00)

> "ขอบเขตของงานคือจำแนก Infiltration กับ No Finding บน 2 ชุดข้อมูล ใช้ ResNet-50 เป็นโมเดลเดียวเพื่อให้ความต่างมาจากวิธีลด Noise อย่างเดียว
> ข้อจำกัดที่ต้องบอกคือ งานนี้เพื่อการศึกษา ไม่ได้ใช้วินิจฉัยจริง, ขอบของ Infiltration กำกวมจึงกระทบทั้ง label และกรอบอ้างอิง, Noise ที่จำลองไม่ได้แทน Noise ของเครื่องจริงทุกแบบ และผลตอนนี้มาจาก seed เดียวกับ test 100 ภาพ ความต่างเล็ก ๆ จึงยังต้องยืนยันครับ"

สไลด์ 20: สรุปผล (45 วินาที | 14:00 – 14:45)

> "สรุป 3 ข้อครับ
> **หนึ่ง** PSNR และ SSIM ที่สูงไม่ได้แปลว่าโมเดลแม่นขึ้น การกรองแรงเกินไปทำให้ฝ้าหายและ AUC ตก
> **สอง** DAE → CLAHE L2 เป็นวิธีภาพเดียวที่ดีที่สุดทั้ง 2 ชุดข้อมูล NIH AUC 0.671 Accuracy 62.13% และ VinBigData AUC 0.997 Accuracy 96.50%
> **สาม** DFT Fusion ที่รวมย่านต่ำ กลาง สูง ได้อันดับ 1 โดยรวมบน VinBigData ที่ 97.81% ครับ"

สไลด์ 21: ขอบคุณ (15 วินาที | 14:45 – 15:00)

> "ขอบคุณอาจารย์และคณะกรรมการทุกท่านครับ พวกผมยินดีรับคำถามและข้อเสนอแนะครับ"