

CS2569/หมายเลขกลุ่ม
เค้าโครงโครงงานคอมพิวเตอร์

การเพิ่มประสิทธิภาพการตรวจจับภาวะปอดอักเสบจากภาพเอกซเรย์ทรวงอกด้วยการลดสัญญาณรบกวนและปัญญาประดิษฐ์ที่อธิบายได้

Enhancing Chest X-RAY Infiltration Detection Using Noise Reduction and Explainable AI

โดย
นายปิยะพล ตุ่นป่า รหัสประจำตัว 673380280-2
นายสัพพัญญู คำตุ้ม รหัสประจำตัว 673380066-4

อาจารย์ที่ปรึกษา อ. ดร.พบพร ด่านวิรุทัย

รายงานนี้เป็นส่วนหนึ่งของการศึกษาวิชา CP353761 สัมมนาทางวิทยาการคอมพิวเตอร์
ภาคเรียนที่ 1 ปีการศึกษา 2569
สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์
มหาวิทยาลัยขอนแก่น
(เดือน ตุลาคม พ.ศ. 2569)

การเสนอเค้าโครงโครงงานคอมพิวเตอร์

สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น

ชื่อ นาย ปิยะพล ตุ่นป่า รหัสประจำตัว 673380280-2
Mr. Piyapon Tunpa
นาย สัพพัญญู คำตุ้ม รหัสประจำตัว 673380066-4
Mr. Sapphanyu Khamtoom
นักศึกษาระดับปริญญาตรี หลักสูตรวิทยาการคอมพิวเตอร์
อาจารย์ที่ปรึกษาโครงงาน ดร.พบพร ด่านวิรุทัย
Project Advisor Dr. Pobporn Danvirutai

1. ชื่อหัวข้อโครงงาน

ภาษาไทย :
การเพิ่มประสิทธิภาพการตรวจจับภาวะปอดอักเสบจากภาพเอกซเรย์ทรวงอกด้วยการลดสัญญาณรบกวนและปัญญาประดิษฐ์ที่อธิบายได้

ภาษาอังกฤษ Enhancing Chest X-RAY Infiltration Detection Using Noise Reduction and Explainable AI

2. หลักการและเหตุผล

โรคระบบทางเดินหายใจและความผิดปกติของปอดถือเป็นหนึ่งในสาเหตุสำคัญของการเจ็บป่วยและเสียชีวิตในระดับสากล โดยเฉพาะภาวะฝ้าในปอดหรือปอดอักเสบแทรกซึม (Pulmonary Infiltration) ซึ่งเกิดจากการสะสมของของเหลว เซลล์อักเสบ หรือหนองในถุงลมปอดจากสาเหตุต่าง ๆ เช่น โรคปอดบวม (Pneumonia) หรือการติดเชื้อในระบบทางเดินหายใจ (World Health Organization [WHO], 2024) การตรวจเอกซเรย์ทรวงอก (Chest X-ray: CXR) จัดเป็นหัตถการรังสีวินิจฉัยด่านแรกที่นิยมใช้มากที่สุดเนื่องจากมีความรวดเร็ว เข้าถึงง่าย และมีค่าใช้จ่ายต่ำ อย่างไรก็ตาม ด้วยปริมาณภาพถ่ายรังสีที่เพิ่มขึ้นอย่างมหาศาล สวนทางกับจำนวนรังสีแพทย์ผู้เชี่ยวชาญ ประกอบกับลักษณะรอยโรคของ Infiltration มักมีลักษณะเป็นฝ้ากระจายตัว ขอบเขตไม่ชัดเจน (Diffuse and Ill-defined Opacity) และกลมกลืนกับเนื้อเยื่อปอดปกติ จึงมักเกิดความแปรปรวนในการอ่านผล (Inter-observer variability) และส่งผลให้แพทย์มีภาระงานสูงจนอาจเกิดความผิดพลาดในการวินิจฉัยเบื้องต้นได้ (Raoof et al., 2012; Wang et al., 2017)

ด้วยเหตุนี้ ในช่วงไม่กี่ปีที่ผ่านมาจึงมีการนำปัญญาประดิษฐ์ โดยเฉพาะการเรียนรู้เชิงลึก (Deep Learning) และโครงข่ายประสาทเทียมแบบคอนโวลูชัน (Convolutional Neural Networks: CNN) มาประยุกต์ใช้เพื่อตรวจจับและจำแนกความผิดปกติจากภาพเอกซเรย์ทรวงอก ซึ่งมีประสิทธิภาพและค่าความแม่นยำสูงในระดับเทียบเท่าผู้เชี่ยวชาญ (Rajpurkar et al., 2017) ทว่าปัญหาสำคัญที่เป็นอุปสรรคต่อการนำไปใช้จริงในงานบริการทางการแพทย์คือ "ปัญหาโมเดลกล่องดำ" (Black-Box Problem) เนื่องจากโครงข่ายประสาทเทียมตัดสินผลลัพธ์ผ่านความสัมพันธ์ทางคณิตศาสตร์ที่ซับซ้อน ทำให้บุคลากรทางการแพทย์ไม่สามารถทราบได้ว่า โมเดลตัดสินใจจากรอยโรคจริงหรือจากสิ่งแปลกปลอม (Artifacts/Confounders) เช่น สายระโยงทางการแพทย์ หรือสัญญาณรบกวน (Noise) บนภาพถ่าย ส่งผลให้ขาดความน่าเชื่อถือและความโปร่งใสในการนำไปสนับสนุนการตัดสินใจทางคลินิก (Rudin, 2019; van der Velden et al., 2022)

เพื่อแก้ปัญหาความโปร่งใส เทคโนโลยีปัญญาประดิษฐ์ที่อธิบายได้ (Explainable Artificial Intelligence: XAI) เช่น Grad-CAM และ SHAP (SHapley Additive exPlanations) จึงเข้ามามีบทบาทสำคัญในการสร้างแผนที่ความสนใจและวิเคราะห์ค่าน้ำหนักฟีเจอร์ระดับพิกเซล (Feature Attribution) เพื่อระบุตำแหน่งรอยโรค (Lundberg & Lee, 2017; Sheu et al., 2023) อย่างไรก็ตาม จากการสังเคราะห์วรรณกรรมพบช่องว่างทางความรู้ที่สำคัญ 2 ประการ

ประการแรก รอยโรคแบบฝ้ากระจาย (Infiltration) มักให้ความแม่นยำและค่า F1-Score ต่ำกว่ารอยโรคที่มีขอบเขตชัดเจน (เช่น Nodule หรือ Cardiomegaly) และแผนภาพอธิบายผลของ AI มักล้มเหลวในการระบุขอบเขตรอยโรคที่แพร่กระจายตัวอย่างถูกต้อง (Chrysoula, 2023)

ประการที่สอง ภาพเอกซเรย์ในเวชปฏิบัติจริงมักมีสัญญาณรบกวนและความเปรียบต่างต่ำ ซึ่งส่งผลกระทบโดยตรงต่อเสถียรภาพของแผนภาพ XAI (Adebayo et al., 2018) แต่การนำเทคนิคการลดสัญญาณรบกวน (Image Denoising) มาใช้ ก็มีความเสี่ยงที่จะเกิดภาวะ Over-smoothing ที่อาจลบรอยฝ้าบางจางของ Infiltration ทิ้งไปพร้อมกับสัญญาณรบกวน นอกจากนี้ งานวิจัยส่วนใหญ่ยังประเมินแผนภาพ XAI เพียงการมองด้วยสายตา (Qualitative) และยังขาดการศึกษาเปรียบเทียบอย่างเป็นระบบ (Fair Comparison) ว่าการลดสัญญาณรบกวนในแต่ละระดับ (เช่น Median Filter, CLAHE+DWT, หรือ Denoising Autoencoder) ช่วยเพิ่มความแม่นยำในการชี้ตำแหน่งรอยโรคจริงของแพทย์ในเชิงปริมาณ (Quantitative Localization) ได้มากน้อยเพียงใด

ดังนั้น คณะผู้จัดทำจึงมีแนวคิดในการพัฒนาโครงงานเรื่อง "การเพิ่มประสิทธิภาพการตรวจจับภาวะปอดอักเสบจากภาพเอกซเรย์ทรวงอกด้วยการลดสัญญาณรบกวนและปัญญาประดิษฐ์ที่อธิบายได้" (Enhancing Chest X-ray Infiltration Detection Using Noise Reduction and Explainable AI) เพื่อศึกษาและเปรียบเทียบผลกระทบของเทคนิคการลดสัญญาณรบกวนรูปแบบต่าง ๆ ต่อความแม่นยำของโมเดล CNN ควบคู่ไปกับการประเมินความถูกต้องของการชี้ตำแหน่งรอยโรคเชิงปริมาณ (Quantitative Localization Evaluation) ผ่านแผนภาพ Grad-CAM และ SHAP เช่น Pointing Game Hit Rate, Energy Inside Bounding Box และ IoU เทียบกับกรอบรอยโรคจริงของรังสีแพทย์ (Ground-Truth Bounding Box) ผลลัพธ์จากโครงงานนี้จะช่วยสร้างความเข้าใจถึงผลกระทบของการเตรียมภาพต่อความสามารถในการอธิบายผลของ AI ป้องกันปัญหา Over-smoothing และยกระดับความน่าเชื่อถือของระบบปัญญาประดิษฐ์สำหรับสนับสนุนการตัดสินใจทางการแพทย์ต่อไปในอนาคต

3. วัตถุประสงค์ของโครงงาน

1. **เพื่อศึกษาและเปรียบเทียบประสิทธิภาพของเทคนิคการลดสัญญาณรบกวน 4 รูปแบบ** ได้แก่ ภาพดั้งเดิม (Baseline), Median Filter, CLAHE ร่วมกับ DWT และ Denoising Autoencoder (DAE) ร่วมกับ CLAHE ต่อความสามารถในการจำแนกภาวะ Infiltration
2. **เพื่อพัฒนาและฝึกสอนแบบจำลองการเรียนรู้เชิงลึก (ResNet-50)** ภายใต้เงื่อนไขการทดลองที่ควบคุมสภาพแวดล้อมอย่างเป็นธรรม (Fair Comparison) เพื่อตรวจจับภาวะ Infiltration จากภาพเอกซเรย์ทรวงอก
3. **เพื่อประยุกต์ใช้เทคนิคปัญญาประดิษฐ์ที่อธิบายได้ (Explainable AI: Grad-CAM, Score-CAM และ SHAP)** ในการแสดงและวิเคราะห์บริเวณรอยโรคที่ส่งผลต่อการตัดสินใจของแบบจำลอง
4. **เพื่อประเมินผลกระทบของการลดสัญญาณรบกวนต่อความแม่นยำในการระบุตำแหน่งรอยโรคของ XAI ในเชิงปริมาณ (Quantitative Localization Evaluation)** ผ่านตัวชี้วัด Pointing Game Hit Rate, Energy Inside Bounding Box และ IoU เทียบกับพิกัดรอยโรคจริงของรังสีแพทย์ (Ground-Truth Bounding Box)

4. ทฤษฎีและผลงานวิจัยที่เกี่ยวข้อง

4.1 พยาธิสภาพของภาวะฝ้าในปอด (Pulmonary Infiltration)

ภาวะ Infiltration ทางรังสีวิทยามีลักษณะเป็นความทึบแสงในเนื้อปอด (Lung Parenchymal Opacity) เกิดจากการที่อากาศในถุงลมปอดถูกแทนที่ด้วยของเหลวหรือเซลล์อักเสบ รอยโรคนี้มีลักษณะสำคัญคือเป็นฝ้าจาง ๆ กระจายตัว (Diffuse, ill-defined, hazy ground-glass opacities) ไม่มีขอบเขตทรงกลมชัดเจนเหมือนก้อนเนื้อ (Mass) หรือจุดเดี่ยว (Nodule) ทำให้การตรวจจับด้วยคอมพิวเตอร์มีความท้าทายสูง โดยเฉพาะเมื่อภาพมีสัญญาณรบกวนทางรังสี (Quantum Noise) หรือถูกบดบังด้วยกระดูกซี่โครง

4.2 สถาปัตยกรรมโครงข่ายประสาทเทียมสำหรับการประมวลผลภาพทางการแพทย์

4.2.1 ResNet-50 (He et al., 2016): สถาปัตยกรรม Residual Network ที่ใช้ Residual Connections ($y = F(x) + x$) ช่วยให้สามารถฝึกฝนโครงข่ายที่มีความลึกสูงได้โดยไม่เกิดปัญหา Vanishing Gradient ในงานวิจัยนี้ถูกใช้เป็นโมเดลหลัก (Fixed Backbone) เพื่อควบคุมตัวแปรให้เป็น Fair Comparison

4.3 เทคนิคการลดสัญญาณรบกวนและการเพิ่มคุณภาพของภาพ (Image Denoising & Enhancement)

4.3.1MedianFilter : ตัวกรองสถิติอันดับที่แทนค่าพิกเซลด้วยค่ามัธยฐานในหน้าต่างพื้นที่ $k \times k$ ช่วยขจัดImpulse Noise ได้ดี แต่ Chattopadhyay (2022) ระบุว่าหากใช้ขนาด Kernel ที่ใหญ่เกินไปจะทำให้เกิด Over-smoothing จนขอบเขตเนื้อเยื่อฝ้าจาง ๆ สูญหาย

4.3.2 CLAHE ร่วมกับ DWT (Chutia et al., 2024): การใช้ Contrast Limited Adaptive Histogram Equalization เพื่อปรับความเปรียบต่างเฉพาะที่ ควบคู่กับการแปลง Discrete Wavelet Transform เพื่อแยกย่อยความถี่และกรองสัมประสิทธิ์ความถี่สูง อย่างไรก็ดี การสังเคราะห์ภาพกลับอาจสร้างสัญญาณแปลกปลอมบริเวณขอบเขตภาพ (Boundary Ringing Artifacts)

4.3.3 Deep Denoising Autoencoder ร่วมกับ CLAHE (Thamilarasi et al., 2025): การใช้โครงข่าย Deep Autoencoder พร้อม Skip Connections ในการเรียนรู้การกระจายตัวของสัญญาณรบกวนทางรังสีเอกซเรย์ปอดโดยเฉพาะ (Unsupervised Learning) ทำให้สามารถกำจัด Noise ได้โดยคงสภาพโครงสร้างทางกายวิภาคและเนื้อเยื่อฝ้าไว้ได้อย่างสมบูรณ์

4.4 ปัญญาประดิษฐ์ที่อธิบายได้ (Explainable AI: XAI)

4.4.1 Grad-CAM (Selvaraju et al., 2017): ใช้ Gradient ของคะแนนคลาสเป้าหมายเทียบกับ Feature Map ใน Convolutional Layer สุดท้ายเพื่อถ่วงน้ำหนักความสำคัญเชิงพื้นที่

4.4.2 SHAP (Lundberg & Lee, 2017): การประยุกต์ใช้ทฤษฎีเกมเพื่อคำนวณค่า Shapley Value ในระดับพิกเซล ทำให้สามารถแยกแยะระหว่างพิกเซลที่สนับสนุนการเกิดโรค (Positive Attribution) กับพิกเซลที่สนับสนุนว่าปอดปกติ (Negative Attribution) ได้อย่างละเอียด

5. วิธีดำเนินการวิจัย

5.1 การจัดหาและคัดเลือกชุดข้อมูลทางการแพทย์ (Dataset Acquisition & Integrity)

1. นำเข้าชุดข้อมูลมาตรฐาน NIH ChestX-ray14 จำนวนรวม 112,120 ภาพ จากผู้ป่วย 30,805 คน
2. ทำการคัดกรองข้อมูลสำหรับโจทย์ Binary Classification:
    2.1. Positive Class: ภาพที่มีฉลากภาวะ Infiltration
    2.2. Negative Class: ต้องเป็นภาพที่มีฉลาก No Finding เท่านั้น (ไม่นำภาพที่มีโรคแทรกซ้อนอื่น เช่น Effusion, Atelectasis มารวม เพื่อป้องกันไม่ให้โมเดลเรียนรู้ฟีเจอร์พยาธิสภาพอื่นปะปน)
3. ตรึงการแบ่งชุดข้อมูลตาม train_val_list.txt และ test_list.txt ของ NIH ซึ่งเป็นการแบ่งระดับผู้ป่วย (Patient-level split) ป้องกันปัญหา Data Leakage 100%
4. คัดเลือกชุดทดสอบมาตรฐานสำหรับการประเมิน XAI จำนวน 100–123 ภาพ ที่ได้รับการยืนยันและมีกรอบ Ground-Truth Bounding Box จากรังสีแพทย์

5.2 การเตรียมและการปรับสภาพข้อมูลภาพ (Data Preprocessing)

1. **การปรับขนาดภาพ**
   ปรับขนาดภาพจาก 1024×1024 พิกเซล เป็น 256×256 และ 224×224 พิกเซล เพื่อให้ได้ขนาดมาตรฐานสำหรับการทดลอง ลดภาระการคำนวณและการใช้หน่วยความจำ การพิจารณาทั้งสองความละเอียดช่วยประเมินความสมดุลระหว่างประสิทธิภาพการประมวลผลกับการรักษารายละเอียดของรอยโรค ซึ่งอาจลดลงเมื่อย่อภาพ
2. **การกำหนดสัญญาข้อมูลภาพ (Image Contract)**
   กำหนดให้ภาพอยู่ในรูปแบบอาร์เรย์ NumPy สองมิติ ชนิดข้อมูล uint8 และมีค่าความสว่างในช่วง [0,255] เพื่อให้ทุกเทคนิคการปรับภาพรับและส่งข้อมูลด้วยมาตรฐานเดียวกัน ลดข้อผิดพลาดจากความแตกต่างของชนิดข้อมูล จำนวนมิติ และช่วงค่าความสว่าง ส่งผลให้กระบวนการประมวลผลมีความสม่ำเสมอ ตรวจสอบได้ และทำซ้ำได้

5.3 การทดลองและเปรียบเทียบเทคนิคการลดสัญญาณรบกวน (Denoising Pipeline)

กำหนดการทดลองเป็น 4 กลุ่ม โดยเพิ่ม ภาพดิบที่ไม่ผ่านการลดสัญญาณรบกวนเป็น Baseline เพื่อใช้ตรวจสอบว่าเทคนิคที่เลือกช่วยให้ผลดีขึ้นจากภาพต้นฉบับหรือไม่ ทั้งนี้ งานวิจัยเดิมมีเป้าหมายและเงื่อนไขการทดลองแตกต่างจากงานนี้ จึงต้องทดสอบผลกับการจำแนก Infiltration โดยตรง พร้อมกำหนดระดับการปรับภาพ L1 – L3 เพิ่มเติม เพื่อศึกษาผลต่อประสิทธิภาพการจำแนก การรักษารายละเอียดฝ้ากระจาย และความสอดคล้องของแผนที่ XAI

กับตำแหน่งรอยโรค โดยระดับดังกล่าวเป็นเงื่อนไขของงานวิจัยนี้ ไม่ได้หมายถึงความแรงที่เทียบเท่ากันระหว่างทุกเทคนิค รายละเอียดของแต่ละกลุ่มมีดังนี้

กลุ่มที่ 1 (Baseline): ภาพดิบที่ผ่านการเตรียมข้อมูลพื้นฐาน แต่ไม่ผ่านการลดสัญญาณรบกวน (Raw CXR)

กลุ่มที่ 2 (Traditional Spatial): Median Filter ที่ขนาด Kernel 3×3 (L1), 5×5 (L2) และ 7×7 (L3)

กลุ่มที่ 3 (Hybrid Frequency): CLAHE + DWT โดยใช้เวฟเล็ต db1 ที่ระดับ L1, L2 และ L3 ซึ่งกำหนดจากค่า Clip Limit ของ CLAHE และค่า Threshold ของ DWT

กลุ่มที่ 4 (Deep Learning Denoising): Denoising Autoencoder (DAE) ที่ฝึกด้วยข้อมูลฝึกของโครงการ ร่วมกับ CLAHE ที่ค่า Clip Limit 2.0 (L1), 4.0 (L2) และ 8.0 (L3) โดยระดับนี้แสดงการปรับความเปรียบต่างหลังผ่าน DAE

5.4 การประเมินคุณภาพการกู้คืนภาพ (Objective Image Quality Metrics)

ประเมินคุณภาพของภาพที่ผ่านการ Denoising บนภาพจำลอง Mixed Poisson-Gaussian Noise ด้วยตัวชี้วัดดังนี้ :

1. **PSNR (Peak Signal-to-Noise Ratio):** วัดความเที่ยงตรงของสัญญาณภาพ
2. **SSIM (Structural Similarity Index):** วัดการรักษารูปร่างและโครงสร้างทางกายวิภาค
3. **EPI (Edge Preservation Index):** วัดการคงอยู่ของขอบเขตเนื้อเยื่อ
4. **CIR (Contrast Improvement Ratio):** วัดการเพิ่มขึ้นของความเปรียบต่างเฉพาะที่

5.5 การฝึกสอนแบบจำลองการจำแนกโรค (Model Training & Fair Comparison)

1. ใช้สถาปัตยกรรม **ResNet-50** โครงสร้างเดียวกัน ไฮเปอร์พารามิเตอร์คงที่ทุกการทดลอง (Batch Size = 32, Learning Rate = 10^{-4}, Cross-Entropy Loss, Adam Optimizer)
2. ทำการ Fine-tune บนภาพที่ผ่านกระบวนการ Denoising แต่ละรูปแบบ โดยใช้ชุดข้อมูล การแบ่งชุดข้อมูล และเงื่อนไขการฝึกเดียวกัน

5.6 การสกัดและสร้างแผนภาพอธิบายผล (XAI Implementation)

1. สกัด HeatMap ของ Infiltration ด้วยเทคนิค Grad-CAM และ SHAP เพื่อแสดงบริเวณที่แบบจำลองทำนาย Infiltration ได้

2. ปรับขนาด Heatmap ให้ตรงกับขนาดภาพตั้งต้น เพื่อให้สามารถซ้อนทับภาพและประเมินความสอดคล้องเชิงตำแหน่งด้วย IoU และ Pointing Game ได้และทำการ Normalize ให้อยู่ในช่วง [0,1]

5.7 การประเมินประสิทธิภาพการจำแนกโรค (Classification Evaluation)

คำนวณค่าตัวชี้วัดมาตรฐานทางการแพทย์บนชุดข้อมูลทดสอบ :

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}}$$

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

$$\text{Sensitivity (Recall)} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

$$\text{F1-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

พร้อมทั้งนำเสนอในรูปแบบ **Confusion Matrix** ทั้งแบบภาพรวมและจำแนกตามสภาวะ

5.8 การประเมินความแม่นยำของการอธิบายผลเชิงสถิติ (XAI Quantitative Localization)

ประเมินความสอดคล้องระหว่าง Saliency Map กับ Bounding Box ของรังสีแพทย์ 100 เคส ด้วย 3 ตัวชี้วัด:

1. Pointing Game Hit Rate (%):

$$\text{Hit} = \mathbb{I}\left(\arg\max_{(x,y)} H(x,y) \in B\right)$$

(ประเมินทั้งแบบ Strict 0px margin และ Margin 5px tolerance)

2. Saliency Energy Inside Bounding Box (%):

$$\text{Energy}_{\text{inside}} = \frac{\sum_{(x,y)\in B} H\,(x,y)}{\sum_{(x,y)\in \text{Image}} H\,(x,y)} \times 100\%$$

3. Intersection over Union (IoU) และ Dice Coefficient:

$$\text{IoU}(\tau) = \frac{|M_\tau \cap B|}{|M_\tau \cup B|}$$

โดยที่

$$M_\tau = \{(x,y) \mid H(x,y) \geq \tau \cdot \max(H)\}$$

ที่ระดับเกณฑ์การตัด $\tau = 0.3$ และ $\tau = 0.5$

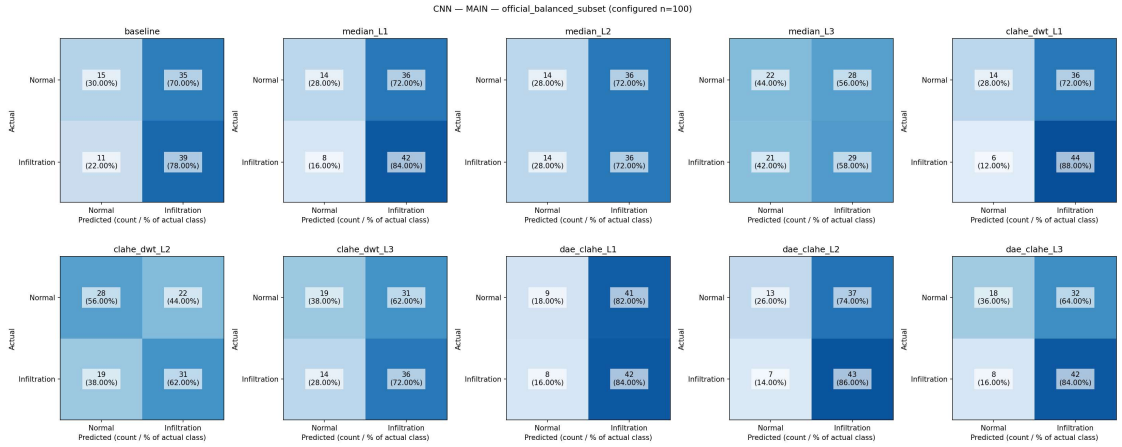
นิยามตัวแปร: $H(x, y)$ คือค่าความสว่างของ Saliency Map ณ พิกัด (x, y), B คือพื้นที่ Bounding Box ของแพทย์, และ $\mathbb{I}(\cdot)$ คือฟังก์ชัน Indicator Function ซึ่งมีค่าเป็น 1 เมื่อจุดสูงสุดตกในกรอบ และเป็น 0 เมื่ออยู่นอกกรอบ

5.9 ผลการศึกษาและทดลองเบื้องต้น (Preliminary Experimental Results) ซึ่งมีผลตัวเลขจริง 2 ส่วนหลักดังนี้ :

ตารางที่ 1 ผลความแม่นยำในการจำแนกโรค (CNN Classification - ResNet-50)
(ทดสอบบนชุด Balanced Test Subset 100 ภาพ: Infiltration 50 ภาพ, No Finding 50 ภาพ)

สภาวะการทดลอง (Condition)	Accuracy	Precision	Recall	F1-Score	ROC-AUC
1. Baseline (Raw CXR)	0.5400	0.5270	0.7800	0.6290	0.6044
2. Median Filter L1	0.5600	0.5385	0.8400	0.6562	0.6164
3. Median Filter L2	0.5000	0.5000	0.7200	0.5902	0.5304
4. Median Filter L3	0.5100	0.5088	0.5800	0.5421	0.5276
5. CLAHE + DWT L1	0.5800	0.5500	0.8800	0.6769	0.6376
6. CLAHE + DWT L2	0.5900	0.5849	0.6200	0.6019	0.6404
7. CLAHE + DWT L3	0.5500	0.5373	0.7200	0.6154	0.6088
8. DAE + CLAHE L1	0.5100	0.5060	0.8400	0.6316	0.6436
9. DAE + CLAHE L2	0.5600	0.5375	0.8600	0.6615	0.6504
10. DAE + CLAHE L3	0.6000	0.5676	0.8400	0.6774	0.6380

(Proposed)					



ภาพที่ 1 เมทริกซ์ความสับสน (Confusion Matrices) เปรียบเทียบผลการจำแนกโรคทั้ง 10 สภาวะการทดลอง

ตารางที่ 2 ผลความแม่นยำของการอธิบายผล XAI เชิงสถิติ (Quantitative Localization)
(ประเมินเทียบกับ Ground-Truth Bounding Box ของรังสีแพทย์ 123 ภาพ จากผู้ป่วย 115 ราย)

สภาวะการทดลอง (Condition)	Grad-CAM Hit Rate (%)	Grad-CAM Energy (%)	SHAP Hit Rate (%)	SHAP Energy (%)
Baseline (ภาพดิบ Raw CXR)	22.76%	16.08%	10.57%	11.20%
Median Filter L1	24.39%	16.78%	8.13%	11.49%
Median Filter L2	26.02%	17.52%	13.01%	11.50%
Median Filter L3	17.07% (ตกฮวบ)	14.92%	13.82%	11.73%
CLAHE + DWT L1	27.64%	16.78%	12.20%	10.95%
CLAHE + DWT L2	27.64%	17.17%	13.82%	11.85%
CLAHE + DWT	23.58%	15.51%	13.01%	10.95%

L3				
DAE + CLAHE L1	33.33%	18.69%	17.07%	12.40%
DAE + CLAHE L2	18.70%	15.01%	19.51%	11.88%
DAE + CLAHE L3 (Proposed)	36.59% (สูงสุด)	20.05%	25.20% (สูงสุด)	13.55%

1. **การพิสูจน์ปัญหา Over-smoothing:** ในกลุ่ม Median Filter เมื่อเพิ่มขนาดจาก 5×5 (L2) เป็น 7×7 (L3) ค่า Grad-CAM Hit Rate ตกฮวบจาก 26.02% เหลือเพียง **17.07%** แสดงให้เห็นชัดเจนว่าการเกลี่ยภาพที่แรงเกินไปลบเลือนขอบเขตฝ้าของ Infiltration
2. **ประสิทธิภาพของ DAE + CLAHE L3:** ได้ผลลัพธ์ดีที่สุดทั้งด้าน Classification (Accuracy 60.0%, F1 0.6774) และด้าน XAI Localization (Grad-CAM Hit Rate สูงสุด **36.59%** และ SHAP Hit Rate สูงสุด **25.20%**) สูงกว่าภาพดิบ Baseline (22.76%) อย่างมีนัยสำคัญ
3. **พฤติกรรมระหว่าง Grad-CAM กับ SHAP:** Grad-CAM ให้ค่า Hit Rate และสัดส่วนพลังงานในกรอบพยาธิสภาพสูงกว่า SHAP เนื่องจาก Grad-CAM เน้นการรวมกลุ่มของพื้นที่ความสนใจระดับ Coarse Region ในขณะที่ SHAP ทำงานระดับพิกเซลเดี่ยว (Fine-grained)

การวิเคราะห์ผลการจำแนกโรคผ่านเมทริกซ์ความสับสน (Confusion Matrix Analysis)

ในการประเมินประสิทธิภาพของแบบจำลอง ResNet-50 บนชุดข้อมูลทดสอบมาตรฐานแบบสมดุล (Balanced Test Subset) จำนวน 100 ภาพ ซึ่งประกอบด้วยภาพปอดปกติ (No Finding) จำนวน 50 ภาพ และภาพที่มีภาวะปอดอักเสบแทรกซึม (Infiltration) จำนวน 50 ภาพ เมทริกซ์ความสับสน (Confusion Matrix) ในแต่ละสภาวะการทดลอง (ดังแสดงในภาพที่ 1) แสดงการกระจายตัวของผลการทำนายออกเป็น 4 มิติสำคัญ ได้แก่ ผลบวกจริง (True Positive: TP), ผลลบจริง (True Negative: TN), ผลบวกลวง (False Positive: FP) และผลลบลวง (False Negative: FN) ซึ่งสามารถสรุปข้อค้นพบเชิงลึกได้ดังนี้:

1. การลดอัตราการวินิจฉัยหลุดรอด (Reduction in False Negatives):

1.1. บนภาพดิบดั้งเดิมที่ไม่ผ่านการปรับปรุง (Baseline Raw CXR) โมเดลสามารถตรวจจับรอยโรค Infiltration ได้ถูกต้อง 39 ภาพ และเกิดการวินิจฉัยหลุดรอด (False Negative: FN) สูงถึง 11 ภาพ (Recall = 78.00%)

1.2. เมื่อประยุกต์ใช้เทคนิค DAE + CLAHE (L1–L3) และ CLAHE + DWT (L1) แบบจำลองสามารถเพิ่มจำนวนการตรวจพบผู้ป่วยจริง (TP) ได้สูงขึ้นเป็น 42–44 ภาพ ส่งผลให้อัตราผลลบลวง (FN) ลดลงเหลือเพียง 6–8 ภาพ เท่านั้น (Recall เพิ่มขึ้น

เป็น 84.00% – 88.00%) ซึ่งมีความสำคัญอย่างยิ่งต่อการใช้งานทางการแพทย์ในฐานะเครื่องมือช่วยคัดกรองเบื้องต้น เพื่อลดความเสี่ยงที่ผู้ป่วยที่มีภาวะปอดอักเสบจะไม่ได้รับการรักษาทันท่วงที

2. **หลักฐานเชิงประจักษ์ยืนยันภาวะ Over-smoothing ใน Median Filter:**
    2.1. ในการทดลองด้วย Median Filter ระดับ L1 (3×3) โมเดลสามารถตรวจจับรอยโรคได้ 42 ภาพ (FN = 8 ภาพ)
    2.2. อย่างไรก็ตาม เมื่อเพิ่มขนาดตัวกรองเป็นระดับ L3 (7×7) ค่าผลลบลวง (FN) กลับพุ่งสูงขึ้นเกือบ 3 เท่าเป็น 21 ภาพ ส่งผลให้ค่า Recall ลดลงฮวบจาก 84.00% เหลือเพียง 58.00% พฤติกรรมนี้เป็นข้อพิสูจน์เชิงประจักษ์ของปรากฏการณ์ Over-smoothing ที่การเกลี่ยภาพที่รุนแรงเกินไปได้ลบเลือนรอยฝ้าจาง ๆ ในถุงลมปอดออกไป ทำให้โมเดลไม่สามารถแยกแยะความแตกต่างระหว่างฝ้า Infiltration กับเนื้อเยื่อปอดปกติได้

3. **ความสมดุลและประสิทธิภาพโดยรวมของ DAE + CLAHE:**
    3.1. สภาวะ DAE + CLAHE L3 แสดงประสิทธิภาพโดยรวมดีที่สุด โดยให้ค่าความแม่นยำรวม (Accuracy = 60.00%) และค่า F1-Score สูงสุด (0.6774) จากการตรวจจับเคสโรคจริงได้สูง (TP = 42 ภาพ) ควบคู่กับการคัดกรองเคสปกติได้ถูกต้องเพิ่มขึ้น (TN = 18 ภาพ)
    3.2. ในขณะที่ CLAHE + DWT L2 มีความโดดเด่นในการลดผลบวกลวง (False Positive) ได้ต่ำที่สุด โดยเกิดการทายผิดในกลุ่มปอดปกติเพียง 22 ภาพ (จากเดิม 35 ภาพใน Baseline) ส่งผลให้ได้ค่า Precision สูงสุดที่ 58.49%

สรุป: ผลจาก Confusion Matrix ยืนยันว่าการใช้โครงข่าย Deep Autoencoder ร่วมกับการปรับความเปรียบต่างเฉพาะที่ (DAE + CLAHE) ช่วยกู้คืนรายละเอียดโครงสร้างทางรังสีวิทยาของรอยโรคแบบฝ้ากระจายตัวได้ดีที่สุด ทำให้แบบจำลองมีความไวในการตรวจจับโรคสูงขึ้นอย่างมีนัยสำคัญเมื่อเทียบกับการใช้ภาพดิบต้นฉบับ

6. ขอบเขตและข้อจำกัดของการวิจัย

6.1 ขอบเขตการวิจัย (Research Scope)

1. ชุดข้อมูลที่ใช้: มุ่งเน้นการตรวจจับภาวะปอดอักเสบ (Infiltration) เทียบกับปอดปกติ (No Finding) จากชุดข้อมูลมาตรฐาน NIH ChestX-ray14 โดยแบ่งชุดข้อมูลระดับผู้ป่วย (Patient-level split) เพื่อป้องกันการรั่วไหลของข้อมูล (Data Leakage)
2. แบบจำลองและอัลกอริทึม: ใช้โครงข่ายประสาทเทียม ResNet-50 เป็นสถาปัตยกรรมหลักภายใต้สภาวะควบคุมคงที่ (Fair Comparison) ร่วมกับเทคนิคการลดสัญญาณรบกวน 4 กลุ่ม (Raw CXR, Median Filter, CLAHE+DWT, และ DAE ร่วมกับ CLAHE)

3. ปัญญาประดิษฐ์ที่อธิบายได้ (Explainable AI): ประยุกต์ใช้เทคนิค Grad-CAM และ SHAP เพื่อสร้างแผนที่ความสนใจเชิงพื้นที่ (Saliency Map)
4. การประเมินผล: ประเมินประสิทธิภาพการจำแนกโรคด้วยตัวชี้วัดทางการแพทย์ (Accuracy, Sensitivity, Specificity, F1-Score) และประเมินความถูกต้องของการชี้ตำแหน่งรอยโรคเชิงสถิติ (Pointing Game Hit Rate, Energy Inside Bounding Box, IoU) เทียบกับพิกัดรอยโรคจริงของรังสีแพทย์

6.2 ขอบเขตด้านเครื่องมือ ซอฟต์แวร์ และทรัพยากรการประมวลผล (Tools & Computing Scope)

1. ภาษาและไลบรารีหลัก: ใช้ภาษา Python ร่วมกับเฟรมเวิร์ก PyTorch และ Torchvision ในการพัฒนาและฝึกสอนแบบจำลองการเรียนรู้เชิงลึก, Scikit-learn สำหรับการประเมินประสิทธิภาพตัวชี้วัดทางการแพทย์ และ OpenCV สำหรับการประมวลผลและปรับปรุงคุณภาพภาพดิจิทัล
2. เครื่องมือสำหรับปัญญาประดิษฐ์ที่อธิบายได้ (XAI): ใช้ไลบรารี PyTorch Grad-CAM สำหรับสร้างแผนที่ความสนใจเชิงพื้นที่ (Saliency Map) และไลบรารี SHAP สำหรับการวิเคราะห์การมีส่วนร่วมของพิกเซล (Pixel Attribution)
3. สภาพแวดล้อมและทรัพยากรการประมวลผล: ดำเนินการบน Google Colab Pro โดยใช้ทรัพยากรหน่วยประมวลผลกราฟิก (GPU) สำหรับการฝึกสอนและทดสอบแบบจำลอง ResNet-50 และ Denoising Autoencoder (DAE)

6.3 ข้อจำกัดของการวิจัย (Limitations)

1. โครงงานนี้จัดทำขึ้นเพื่อวัตถุประสงค์ทางการศึกษาและการวิจัยเบื้องต้นเท่านั้น มิได้มุ่งหมายให้นำไปใช้วินิจฉัยโรคทางคลินิกจริงโดยไม่ผ่านการตรวจสอบและรับรองจากผู้เชี่ยวชาญทางการแพทย์
2. รอยโรค Infiltration มีลักษณะเป็นฝ้ากระจายตัว ขอบเขตไม่ชัดเจน และมีความแปรปรวนของการอ่านผลระหว่างแพทย์ผู้เชี่ยวชาญ (Inter-observer variability) ซึ่งอาจส่งผลต่อความแม่นยำของกรอบ Bounding Box อ้างอิง

7. สถานที่ทำวิจัย

สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น

8. ประโยชน์ที่คาดว่าจะได้รับ

1. ได้แนวทางการเพิ่มประสิทธิภาพการตรวจจับภาวะปอดอักเสบจากภาพเอกซเรย์ทรวงอกด้วยการลดสัญญาณรบกวนร่วมกับปัญญาประดิษฐ์
2. ได้แบบจำลองปัญญาประดิษฐ์ที่สามารถอธิบายเหตุผลของผลการทำนายได้ ซึ่งช่วยเพิ่มความน่าเชื่อถือและความโปร่งใสในการนำไปใช้สนับสนุนการวินิจฉัยของบุคลากรทางการแพทย์

3. เป็นแนวทางและองค์ความรู้พื้นฐานสำหรับการต่อยอดงานวิจัยด้านการประยุกต์ใช้ปัญญาประดิษฐ์ที่อธิบายได้ในภาพทางการแพทย์ประเภทอื่น ๆ ต่อไป
4. ผู้จัดทำได้ฝึกฝนทักษะการทบทวนวรรณกรรม การพัฒนาแบบจำลองปัญญาประดิษฐ์ และการวิเคราะห์ผลอย่างเป็นระบบ ซึ่งเป็นประโยชน์ต่อการศึกษาและการทำงานในอนาคต

9. แผนและระยะเวลาดำเนินการ

ตารางที่ 3 แผนและระยะเวลาดำเนินการ

การดำเนินงาน	ปี2569				ปี2570		
	9	10	11	12	1	2	3
1 การจัดหาและคัดเลือกชุดข้อมูลทางการแพทย์ (Dataset Acquisition & Integrity)	X						
2 การเตรียมและการปรับสภาพข้อมูลภาพ (Data Preprocessing)	X						
3 การทดลองและเปรียบเทียบเทคนิคการลดสัญญาณรบกวน (Denoising Pipeline)		X					
4 การประเมินคุณภาพการกู้คืนภาพ (Objective Image Quality Metrics)		X					
5 การฝึกสอนแบบจำลองการจำแนกโรค (Model Training & Fair Comparison)			X	X	X		
6 การสกัดและสร้างแผนภาพอธิบายผล (XAI Implementation)						X	
7 การประเมินประสิทธิภาพการจำแนกโรค							X
8 การประเมินความแม่นยำของการอธิบายผลเชิงสถิติ (XAI Quantitative Localization)							X

10. งบประมาณ (Budget)

ในการดำเนินโครงงานวิจัยนี้ มีการประมาณการค่าใช้จ่ายแยกตามหมวดหมู่ ดังนี้

1. หมวดค่าบริการระบบคลาวด์และทรัพยากรคำนวณ
    1.1. ค่าบริการGoogle Colab Pro (1500 บาท/เดือน × 6 เดือน) เป็นเงิน 9,000 บาท
2. หมวดวัสดุคอมพิวเตอร์และอุปกรณ์สำรองข้อมูล
    2.1. ค่าอุปกรณ์สำรองข้อมูลความเร็วสูง (Portable SSD/Flash Drive) จำนวน 1 ชุด เป็นเงิน 1,200 บาท
3. หมวดค่าใช้สอยและการจัดพิมพ์เอกสาร
    3.1. ค่าจัดทำเอกสารเสนอเค้าโครงโครงงาน (4 เล่ม × 60 บาท) เป็นเงิน 240 บาท
    3.2. ค่าจัดทำรูปเล่มรายงานโครงงานฉบับสมบูรณ์ (4 เล่ม × 150 บาท) เป็นเงิน 600 บาท
    3.3. ค่าจัดพิมพ์โปสเตอร์นำเสนอผลงานวิจัย (1 แผ่น) เป็นเงิน 400 บาท

รวมเป็นเงินงบประมาณทั้งสิ้น 11,440 บาท

11. เอกสารอ้างอิง

1. Adebayo, J., Gilmer, J., Muelly, M., Goodfellow, I., Hardt, M., & Kim, B. (2018). Sanity checks for saliency maps. In *Advances in Neural Information Processing Systems* (Vol. 31, pp. 9505–9515). NeurIPS. https://proceedings.neurips.cc/paper/2018/hash/294a8ed24b1ad22ec2e7efea049b873a-Abstract.html
2. Byeon, H., Seno, M. E., Nimma, D., Ramesh, J. V. N., Zaidi, A., AlGhamdi, A., ... & Shabaz, M. (2025). Privacy-preserving explainable AI enable federated learning-based denoising fingerprint recognition model. *Image and Vision Computing*, 154, 105420. https://doi.org/10.1016/j.imavis.2025.105420
3. Chattopadhyay, S. (2022). A study on various common denoising methods on chest X-ray images. *Artificial Intelligence Evolution*, 3(2), 87–106. https://doi.org/10.37256/aie.3220221714
4. Chrysoula, T. (2023). *Explainable artificial intelligence for deep learning methods in chest X-ray classification* [Master's thesis, National and Kapodistrian University of Athens]. https://pergamos.lib.uoa.gr/uoa/dl/object/3396182
5. Chutia, U., Tewari, A. S., & Singh, J. P. (2024). Collapsed lung disease classification by coupling denoising algorithms and deep learning techniques. *Network Modeling Analysis in Health Informatics and Bioinformatics*, 13(1), 1. https://doi.org/10.1007/s13721-023-00435-0
6. Dhar, T., Dey, N., Borra, S., & Sherratt, R. S. (2023). Challenges of deep learning in medical image analysis—improving explainability and trust. *IEEE Transactions on Technology and Society*, 4(1), 68–75. https://doi.org/10.1109/TTS.2023.3234203
7. Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems* (Vol. 30, pp. 4765–4774). NeurIPS. https://doi.org/10.48550/arXiv.1705.07874
8. Parra-Cabrera, G., Jimenez-Delgado, J. J., & Perez-Cano, F. D. (2026). Artificial intelligence for pulmonary abnormality detection in chest X-ray imaging: A detailed review of methods, datasets and future directions. *Technologies*, 14(3), 147. https://doi.org/10.3390/technologies14030147

9. Rahman, T., Khandakar, A., Qiblawey, Y., Tahir, A., Kiranyaz, S., Kashem, S. B. A., ... & Chowdhury, M. E. (2021). Exploring the effect of image enhancement techniques on COVID-19 detection using chest X-ray images. *Computers in Biology and Medicine*, 132, 104319. https://doi.org/10.1016/j.compbiomed.2021.104319
10. Rajpurkar, P., Irvin, J., Zhu, K., Yang, B., Mehta, H., Duan, T., Ding, D., Bagul, A., Langlotz, C., Shpanskaya, K., Lungren, M. P., & Ng, A. Y. (2017). CheXNet: Radiologist-level pneumonia detection on chest X-rays with deep learning. *arXiv*. https://doi.org/10.48550/arXiv.1711.05225
11. Raoof, S., Feigin, D., Sung, A., Raoof, S., Irugulpati, L., & Rosenow, E. C. (2012). Interpretation of plain chest roentgenogram. *Chest*, 141(2), 545–558. https://doi.org/10.1378/chest.10-1302
12. Rudin, C. (2019). Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. *Nature Machine Intelligence*, 1(5), 206–215. https://doi.org/10.1038/s42256-019-0048-x
13. Sheu, R. K., Pardeshi, M. S., Pai, K. C., Chen, L. C., Wu, C. L., & Chen, W. C. (2023). Interpretable classification of pneumonia infection using eXplainable AI (XAI-ICP). *IEEE Access*, 11, 28896–28919. https://doi.org/10.1109/ACCESS.2023.3255403
14. Song, L., Sun, H., Xiao, H., Lam, S. K., Zhan, Y., Ren, G., & Cai, J. (2025). Artificial intelligence for chest X-ray image enhancement. *Radiation Medicine and Protection*, 6(01), 61–68. https://doi.org/10.1016/j.radmp.2024.12.003
15. Thamilarasi, V., Asaithambi, A., & Roselin, R. (2025). Enhanced ensemble segmentation of lung chest X-ray images by denoising autoencoder and CLAHE. *ICTACT Journal on Image and Video Processing*, 15(3), 3501–3508. https://doi.org/10.21917/ijivp.2025.0496
16. van der Velden, B. H. M., Kuijf, H. J., Gilhuijs, K. G. A., & Viergever, M. A. (2022). Explainable artificial intelligence (XAI) in deep learning-based medical image analysis. *Medical Image Analysis*, 79, Article 102470. https://doi.org/10.1016/j.media.2022.102470
17. Wang, X., Peng, Y., Lu, L., Lu, Z., Bagheri, M., & Summers, R. M. (2017). ChestX-ray8: Hospital-scale chest X-ray database and benchmarks on weakly-supervised classification and localization of common thorax diseases. In *Proceedings of the*

IEEE Conference on Computer Vision and Pattern Recognition (CVPR) (pp. 2097–2106). https://doi.org/10.1109/CVPR.2017.369

18. World Health Organization. (2024). *The top 10 causes of death*. World Health Organization. https://www.who.int/news-room/fact-sheets/detail/the-top-10-causes-of-death

ลงชื่อผู้ทำโครงงาน .....
(นาย/นางสาว .....)
วันที่ .....

ลงชื่อผู้ทำโครงงาน .....
(นาย/นางสาว .....)
วันที่ .....

การตรวจสอบจากอาจารย์ที่ปรึกษาโครงงาน

( ) ตรวจสอบแล้ว เห็นชอบตามเสนอ

( ) อื่น ๆ .....

(ลงชื่อ) .....
(.....)
วันที่ .....